

StyleGallery: Training-free and Semantic-aware Personalized Style Transfer from Arbitrary Image References

Boyu He Yunfan Ye Chang Liu Weishang Wu Fang Liu Zhiping Cai

National University of Defense Technology

Hunan University


CVPR 2026

- **Type:** Style Transfer trên Diffusion Model
- **Năm:** 2026
- **Hội nghị:** CVPR 2026
- **Link Code:** <https://github.com/iiiiiiiword/StyleGallery>
- **Keywords:** Style Transfer, Diffusion Models, Semantic-aware, Training-free, Personalized Customization.

Problem Setup: Bài toán Style Transfer

Style Transfer là bài toán gì?

- Là bài toán kinh điển thuộc nhóm Computer Vision / Image Generation.
- **Mục tiêu:** Biến đổi một ảnh nội dung (content image) theo phong cách thị giác của một ảnh phong cách (style reference).
- **Thách thức cốt lõi:** Giữ nguyên vẹn cấu trúc và ngữ nghĩa (semantics) của ảnh content, trong khi áp dụng chính xác các texture, màu sắc, và đường nét (brushstrokes) từ ảnh style.



Hình: Minh họa quá trình Style Transfer.

Problem Setup: Image-to-Image vs. Text-to-Image

- **Text-to-Image (T2I) Style Transfer:**

- *Input:* Ảnh content và một text prompt mô tả style (ví dụ: "in Van Gogh style").
- *Đặc điểm:* Linh hoạt, dễ điều khiển qua ngôn ngữ tự nhiên nhờ các Diffusion Models mạnh mẽ.
- *Thách thức:* Rất khó mô tả các style cá nhân hóa hoặc trừu tượng (abstract) chỉ bằng text prompt; dễ bị sai lệch ngữ nghĩa (semantic deviation) do prompt không đủ tính bao quát.

- **Image-to-Image (I2I) Style Transfer:**

- *Input:* Ảnh content và ảnh style reference (1 hoặc nhiều).
- *Đặc điểm:* Bắt chước chính xác các chi tiết thị giác đặc thù từ một tác phẩm thực tế. Rất phù hợp cho personalized customization.
- *Thách thức:* Cần cơ chế feature matching phức tạp để căn chỉnh đúng các vùng không gian giữa hai ảnh.

Dù sử dụng mô hình nào (CNN, Transformer, hay Diffusion Models), bài toán vẫn tồn tại các giới hạn cốt lõi:

- ❶ **Semantic Mismatch (Ghép sai ngữ nghĩa):** Áp dụng sai style vào các vùng không tương đồng (ví dụ: lấy style của bầu trời đắp lên khuôn mặt người).
- ❷ **Content Leakage (Rò rỉ/Biến dạng nội dung):** Cấu trúc vật lý của ảnh gốc bị phá hủy do bị các họa tiết của style chen lấn quá mức (over-stylization).
- ❸ **Under-stylization (Chưa thể hiện rõ style):** Không truyền tải được phong cách nghệ thuật, sinh ra các pattern ngẫu nhiên (random patterns) khi gập background màu trơn.
- ❹ **Khó khăn trong cá nhân hóa (Personalization):** Rất khó để tổng hợp và transfer style từ một bộ sưu tập (gallery) nhiều reference images cùng lúc mà không làm nhiễu hệ thống.

From Gaps to Contributions

Từ những nút thắt trên, bài báo chỉ ra 3 Gaps chính và dẫn dắt ra các Contributions tương ứng:

- **1. Semantic Gap:** Một style reference duy nhất thường thiếu các vùng semantic phù hợp với content.
→ **Arbitrary Image References:** Đề xuất framework hỗ trợ truyền input số lượng ảnh reference tùy ý (tạo thành một gallery).
- **2. Extra Constraint:** Thường phụ thuộc vào external semantic masks (như SAM) để tránh ghép sai, gây hạn chế ứng dụng.
→ **Training-free & Tự động:** Tự động phân cụm (adaptive clustering) trực tiếp trên latent diffusion features, không cần external models.
- **3. Rigid Features:** Các model (như StyleID) thiếu sự căn chỉnh (alignment) global-local thích ứng, gây mất cân bằng fine-grained.
→ **Cơ chế Matching & Optimize:** Matching đa chiều (semantic matching) kết hợp hàm loss cục bộ/toàn cục (RSL & GCL) để hướng dẫn diffusion sampling.

- **Framework:** Một framework training-free và semantic-aware cho style transfer từ các image reference tùy ý, hỗ trợ lựa chọn personalized.
- **Thiết kế kỹ thuật (Technical Designs):** Clustering thích ứng, semantic matching, và các hàm tối ưu hóa để ngăn chặn stylization kém và content leakage.
- **Dataset:** Một dataset mới chứa đa dạng các style galleries (25 họ style, 750 stylized images) để đánh giá multiple-reference style transfer.

1. Latent Diffusion Models (LDM)

- Là mô hình tạo sinh (generative model) tiên tiến, hoạt động trong không gian latent (latent space) để giảm thiểu tối đa chi phí tính toán (computational overhead).
- **Cơ chế hoạt động:**
 - Một VAE đã pre-trained được sử dụng để mã hóa (encode) ảnh đầu vào thành một biểu diễn latent.
 - Mạng khử nhiễu (denoising network) $\epsilon_{\theta}(\cdot)$ dựa trên kiến trúc UNet được huấn luyện để dự đoán nhiễu (noise) tại mỗi bước của quá trình diffusion.
- **Hàm mục tiêu (Objective function):** Tối thiểu hóa sai số toàn phương trung bình (MSE) giữa nhiễu dự đoán ϵ_{θ} và nhiễu thực tế ϵ được thêm vào:

$$\mathcal{L}_{\text{LDM}} = \mathbb{E}_{z, y, \epsilon, t} \left[\|\epsilon - \epsilon_{\theta}(z_t, t, y)\|_2^2 \right] \quad (1)$$

Trong đó: $\epsilon \in \mathcal{N}(0, 1)$ là nhiễu, t là timestep, và y là điều kiện (condition).

2. Attention Mechanisms in Diffusion

- Cơ chế Self-Attention (SA) và Cross-Attention (CA) đóng vai trò then chốt trong kiến trúc diffusion dựa trên UNet.
- Các attention maps có khả năng tích hợp thông tin mạnh mẽ, giúp nắm bắt thông tin về cấu trúc và content của ảnh. Bài báo tập trung vào module SA cho tác vụ style transfer:

$$\text{Self-Attn}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d}}\right) V \quad (2)$$


Trong đó: Q, K, V đại diện cho các visual features và d là số chiều feature dùng để scaling.

3. Diffusion Features

- Dựa trên framework trích xuất đặc trưng không giám sát (DIFT), việc thêm Gaussian noise có kiểm soát vào ảnh và trích xuất các intermediate UNet activations giúp tạo ra các biểu diễn ở cấp độ pixel (pixel-level representations).
- **Ứng dụng vào Method:** Bài báo áp dụng K-means clustering nhận diện ngữ nghĩa lên các UNet feature maps này để xác định các vùng semantic riêng biệt. Từ đó, tiến hành phân rã các attention features và xử lý tách biệt từng vùng để đạt được khu vực style transfer chuẩn xác.


4. K-means Clustering

- Là thuật toán phân cụm (clustering) cốt lõi thuộc nhóm học không giám sát (unsupervised learning).
- **Mục tiêu:** Phân chia dữ liệu thành K cụm (clusters) dựa trên khoảng cách đặc trưng, sao cho các điểm trong cùng một cụm có độ tương đồng (similarity) cao nhất.
- **Ứng dụng trong StyleGallery:**
 - Tác giả áp dụng K-means (semantic-aware) trực tiếp lên các intermediate UNet feature maps (cụ thể là F_{mix}).
 - Quá trình này giúp mô hình tự động nhận diện và gom nhóm các pixel thành các vùng ngữ nghĩa (distinct semantic regions) riêng biệt.
 - Nhờ K-means, framework có thể phân rã ảnh thành các vùng để xử lý tách biệt mà hoàn toàn không bị phụ thuộc vào các external mask models.



Hình: Minh họa thuật toán K-means Clustering.

Method Overview: Pipeline 3 Stages



Hình: StyleGallery Pipeline: Segment (Phân vùng) → Match (Ghép cặp) → Optimize (Tối ưu)

- **Mục tiêu:** Cho một tập ảnh style I_s và ảnh content I_c , StyleGallery nhận diện các vùng semantic tương đồng một cách thích ứng để thực hiện stylization.
- **Lợi thế:** Giúp bảo toàn cấu trúc content gốc và giảm thiểu hiện tượng semantic leakage.
- **Giai đoạn 1 (Phân loại cụm - DFCC):**
 - Mô hình thực hiện DDIM inversion qua T timesteps trên cả hai ảnh.
 - Trích xuất và kết hợp (fuse) các intermediate features của mạng UNet thành một feature thống nhất.
 - Áp dụng thuật toán K-means clustering để xác định các vùng semantic.
 - Các semantic masks sau đó được tinh chỉnh thông qua quá trình cluster optimization.

- **Giai đoạn 2 (Matching các vùng):** Độ tương đồng giữa các vùng được tính toán dọc theo 3 chiều:
 - *Đặc trưng thống kê (Statistical similarity):* Rút ra từ các số liệu thống kê của U-Net feature.
 - *Độ tương đồng ngữ nghĩa (Semantic similarity):* Tính toán từ các region features được trích xuất bởi mô hình DINOv2.
 - *Độ tương đồng vị trí (Positional similarity):* Rút ra từ các vòng tròn bao quanh nhỏ nhất (minimum enclosing circles) của từng cụm.
- **Giai đoạn 3 (Tối ưu hóa Sampling):** Trong suốt N bước sampling, các self-attention features của UNet được dùng để tối thiểu hóa khoảng cách L1 giữa feature maps thực tế và feature maps lý tưởng, qua đó hướng dẫn quá trình sinh ảnh cuối cùng.

Stage 1: Diffusion Features for Cluster Classification

- Khác với các phương pháp dựa trên pixel-to-pixel (như Semantix) hay cần semantic segmentation maps (như SCSA), StyleGallery áp dụng chiến lược semantic clustering training-free dựa trên DIFT.
- **Nguyên lý:** Đưa một ảnh vào pre-trained Diffusion model, trích xuất các intermediate feature maps của UNet thông qua forward diffusion, sau đó dùng chính các maps này để phân biệt các vùng semantic khác nhau.
- **Quy trình 4 bước bắt đầu với:**
 - **Bước 1:** Trích xuất các feature maps từ UNet cho tác vụ semantic clustering và thu được initial noisy feature map.
 - **Bước 2:** Áp dụng tính toán trọng số thích ứng theo chỉ số (index-adaptive weighting) lên chuỗi feature map để thu được feature hỗn hợp F_{mix} .


Stage 1: Diffusion Features for Cluster Classification

- Công thức tính trọng số (Bước 2):

$$d(t) = \frac{1}{1 + \exp(-5 \cdot (\frac{t}{T} - 0.7))}, \quad F_{mix} = \sum_t^T \left(\frac{d(t)}{\sum_k^T d(k)} \right) \cdot F_t \quad (3)$$


- Các siêu tham số (hyperparameters) -5 và 0.7 được dùng để kiểm soát độ dốc và điểm uốn của đường cong trọng số.
- Ví dụ: $T = 20$

$$d(t) = \frac{1}{1 + \exp(-5 \cdot (\frac{t}{20} - 0.7))} \quad w(t) = \frac{d(t)}{\sum_{k=1}^{20} d(k)} \quad \sum_{k=1}^{20} d(k) \approx 7.0833$$



Stage 1: Cluster Optimization Mechanism

- **Bước 3:** Thực hiện giảm chiều dữ liệu PCA và áp dụng K-means clustering lên F_{mix} .
- **Bước 4:** Cluster Optimization, quá trình này dựa trên độ tương đồng semantic (semantic similarity) và việc hợp nhất các cụm điểm cô lập (isolated point clusters) với lân cận gần nhất của chúng.



Hình: Gộp các khoảng cách semantic theo cặp (pairwise) và loại bỏ các điểm cô lập.

Stage 2: Cluster Matching

- Do ảnh content và ảnh style có sự khác biệt về phong cách, màu sắc, hình dáng và texture, mô hình căn chỉnh các semantic regions tương ứng bằng cách tính toán điểm tương đồng trên 3 chiều feature.
- **Chiều 1 (Statistical Features):** Áp dụng cluster mask lên fused feature map để cô lập feature từ các vùng semantic khác nhau. Dùng self-attention để tổng hợp các mối quan hệ và tính toán đặc trưng thống kê (mean, variance) cho từng cluster.
- **Chiều 2 (Semantic Similarity):** Đưa ảnh vào DINOv2 để lấy các semantic feature tokens và định dạng lại (reshape) cluster mask để khớp với các tokens này. Kết nối (concatenate) các tokens nếu số lượng hợp lệ lớn hơn 100 để tạo thành cluster features, sau đó tính cosine similarity.

Stage 2: Cluster Matching (Phần 2)

- **Chiều 3 (Geometric Criterion):** Khi sự tương quan ngữ nghĩa giữa ảnh content và style yếu, mô hình sẽ tính toán vòng tròn bao quanh nhỏ nhất (minimum enclosing circle) cho mỗi cluster để lấy thông tin vị trí (tâm và bán kính), cung cấp thêm dữ liệu cho quá trình matching.
- **Công thức khớp ngữ nghĩa (Semantic matching formula):**

$$\text{Similarity} = \sum_i \lambda_i * CS(\text{feat}_i^c, \text{feat}_i^s) \quad (4)$$

- Trong đó, λ_i là trọng số của chiều thứ i , và feat_i^c , feat_i^s là features từ các cluster của ảnh content và style thu được qua semantic clustering masks.
- $CS(a, b)$ là cosine similarity giữa hai vectors. Tác giả thiết lập $\lambda_1 = 0.25$, $\lambda_2 = 1$, và $\lambda_3 = 0.125$.

Stage 3: Sampling Optimization

- Sau khi thiết lập được semantic region matching, thách thức tiếp theo là truyền các regional style features sang đúng vùng tương ứng trên ảnh content. **Self-Attention trong UNet:**

$$\text{Self-Attn}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d}}\right) V \quad (5)$$

- Giải pháp sử dụng 2 hàm loss chính:
- **(1) Regional Style Loss (RSL):**
 - Trích xuất các features Q, K, V từ 6 layers self-attention cuối của UNet.
 - Dùng semantic cluster mask để làm thưa (sparsify) features cho từng cụm bằng cách đưa các điểm không liên quan về 0 (zeroing out).
 - Feature weight mask này ép Q, K, V chỉ giữ lại trọng số cho vùng semantic liên quan.
 - Tính toán L1 loss giữa mỗi cặp vùng semantic đã ghép cặp:

$$\mathcal{L}_{\text{RSL}} = \sum_{i,j} \left\| \text{Mask}(\text{Self-Attn}(Q_i, K_i, V_i)) - \text{Self-Attn}(\text{Mask}(Q_i), K_j^s, V_j^s) \right\|_1$$

Stage 3: Sampling Optimization

- **(2) Global Content Loss (GCL):** Để duy trì tính nhất quán về nội dung giữa ảnh được sinh ra và ảnh gốc, tác giả dùng content loss (tính bằng L1 distance) giữa feature Q từ generated branch và Q_c từ content branch:

$$\mathcal{L}_{\text{GCL}} = \|Q - Q_c\|_1 \quad (6)$$

- **Hàm loss tổng thể (Overall loss):**


$$\mathcal{L}_{\text{RST}} = \mathcal{L}_{\text{RSL}} + \lambda_c * \mathcal{L}_{\text{GCL}} \quad (7)$$

λ_c là tỷ lệ content loss được điều chỉnh để kiểm soát kết quả sinh ảnh.

- Diễn giải $\mathcal{L}_{\text{RST}}$ như một hàm năng lượng (energy function) để dẫn dắt quá trình DDIM sampling. Trình tối ưu hóa Adam sẽ cập nhật latent vector z_{t-1} :

$$z_{t-1} = z_{t-1} - \eta \nabla_{z_{t-1}} \mathcal{L}_{\text{RST}}(z_{t-1}, z_{t-1}^{\text{ref}}) \quad (8)$$

Giai đoạn 3: Sparse Attention



Hình: Masking trên các attention feature map để giữ lại các ngữ nghĩa liên quan.

- **Dataset:** 750 stylized images từ COCO, FFHQ, WikiArt. 25 họ style (Van Gogh, Chinese ink,...). Input từ 1-5 style images tùy ý cho mỗi content.
- **Baselines:**
 - CNN: CAST, CCPL
 - Transformer: AdaAttn, StyTR-2
 - Diffusion: CSGO, StyleShot, StyleID, AD, AttnST
- **Metrics:**
 - *Style* ↑: Thuật toán Hungarian matching trên các VGG blocks.
 - *Structure* ↓: Gram Loss, FID, LPIPS.
 - *Overall* ↓: ArtFID.

Qualitative Results

Methods		CNN-based		Transformer-based		Diffusion-based							
  <i>VanGogh Style</i>	  <i>Oil Painting Style</i>												
													
													
													
Content	Styles	CAST (SIGGRAPH 2022)	CCPL (ECCV 2022)	AdaAttn (ICCV 2021)	StyTR-2 (CVPR 2022)	CSGO (arXiv 2024)	StyleShot (arXiv 2024)	StyleID (CVPR2024)	AD (CVPR2025)	Artist* (ACM MM 2025)	AttnST (arXiv 2025)	StyleSSP (CVPR 2025)	Ours


Hình: StyleGallery đạt được style transfer ở mức độ semantic trong khi vẫn bảo toàn được cấu trúc content.

Quantitative Results

Metric	CAST [45]	CCPL [44]	AdaAttn [29]	StyTR-2 [5]	CSGO [46]	StyleShot [8]	StyleID [4]	AD [53]	AttnST [16]	Ours
Style $\uparrow$	0.4959	0.5163	0.5094	0.5219	0.5224	0.5198	0.4972	<u>0.5249</u>	0.5032	0.5337
Gram Loss $\downarrow$	15.778	17.8606	17.357	16.719	19.937	19.013	14.261	<u>13.862</u>	16.937	13.519
FID [15] $\downarrow$	<u>17.255</u>	18.141	18.498	17.623	19.829	20.638	18.987	17.677	19.233	16.889
LPIPS [49] $\downarrow$	0.4934	0.4549	0.5299	<u>0.3856</u>	0.5005	0.6615	0.4496	0.4032	0.4532	0.3716
ArtFID [43] $\downarrow$	27.262	27.843	29.831	<u>25.804</u>	31.254	35.952	28.973	26.207	29.402	24.536

Hình: StyleGallery đạt kết quả SOTA ở nhiều metrics

Results: Chi tiết Zoom & So sánh với SCSA



Hình: So sánh với phương pháp dựa trên mask (SCSA).

Hình: Tránh được các pattern lỗi của StyleID.

Thực nghiệm Ablation: Loss & Masks




Hình: Hiệu quả của Content Loss, Style Loss, và Semantic Masks.


Configuration	LPIPS [49] ↓	FID [15] ↓	Style ↑
Ours ($\lambda_c = 0.26$, default)	0.3716	16.89	0.5337
Ours ($\lambda_c = 0.29$, above)	0.3689	27.26	0.4172
Ours ($\lambda_c = 0.22$, below)	0.4354	21.84	0.4562
w/o RSL	0.5195	23.56	0.4387
w/o GCL	0.6822	30.83	0.4150

Hình: Tác động trực quan khi điều chỉnh trọng số content loss λ_c .

Robustness & Acceleration



Hình: LCM & Hyper-SD giúp giảm số bước (150→28).



(a) Results of abstract styles



(b) Results of inaccurate generated masks

Hình: Robustness trên các style trừu tượng & mask lỗi.



- **Điểm mạnh:**

- **Training-free:** Áp dụng được ngay lên các Diffusion Models đã pre-trained.
- **Tính linh hoạt cao:** Hỗ trợ số lượng reference tùy ý.
- **Zero Extra Input:** Semantic segmentation độc lập, không cần external models.
- **Tính diễn giải (Interpretability):** Region matching thích ứng, fine-grained giúp giải quyết semantic leakage.
- Thuật toán có thể thực hiện với nhiều style image.



- **Điểm hạn chế:**

- **Phụ thuộc Mask:** Cluster masks lỗi (do cấu trúc chồng chéo phức tạp) có thể làm hỏng một phần stylization.
- **Abstract Styles:** Các input quá trừu tượng, ít dấu hiệu semantic vẫn là thách thức cho quá trình matching cục bộ.
- Không đảm bảo kết quả nếu Style-image và Content-image không quá tương đồng về semantic.

Supplementary: Phân tích Dataset



Phụ lục: Optimization & Thresholds



Phụ lục: Giao diện người dùng (UI)

75%

Q10. Please rate the results generated by the three different methods using the evaluation metrics we provide.

(Click on the image to enlarge it.)




Result1


Result2

Result3

	Result1	Result2	Result3
The degree of local stylization	★★★★★	★★★★★	★★★★★



Phụ lục: Các kết quả bổ sung



Phụ lục: Thêm kết quả Stylization (1)




Phụ lục: Thêm kết quả Stylization (2)




Phụ lục: Thêm kết quả Stylization (3)



Phụ lục: Custom & So sánh với LLM



Hình: Customizations



Hình: So sánh với các Large Models